

2 Notwendige Bedingungen erster Ordnung für Optimalsteuerprobleme

2.1 Quadratische Optimierungsprobleme im Hilbertraum

Wir betrachten grundsätzlich das Problem

$$\min_{u \in U_{\text{ad}}} j(u) = \frac{1}{2} \|Su - y_d\|_H^2 + \frac{\lambda}{2} \|u\|_U^2,$$

wobei U und H Hilberträume sind und U_{ad} eine konvexe und abgeschlossene Menge. Der Operator $S: U \rightarrow H$ sei linear und stetig. Die Existenz einer Lösung dieses Problems folgt direkt aus [Satz 1.2.9](#).

derivative concept

optimality
conditions

Für die Optimalitätsbedingungen benötigen wir Ableitungsbegriffe. Das kennt man schon aus der Schule. Sei dazu $F: U \rightarrow V$ gegeben.

directional
derivative

- **Richtungsableitung:** Existiert der Grenzwert

$$\delta F(u, h) = \lim_{t \downarrow 0} \frac{F(u + th) - F(u)}{t} \quad \text{in } V$$

in V , so heißt F richtungsdifferenzierbar in u in Richtung h .

- **Erste Variation:** Existiert die Richtungsableitung in alle Richtungen h , so heißt die Abbildung $h \mapsto \delta F(u; h)$ auch *erste Variation*.
- **Gâteaux-Ableitung:** Ist die erste Variation in u linear und stetig, so heißt der entsprechende lineare Operator A *Gâteaux-Ableitung* in u ; wir schreiben auch $A = F'(u)$.
- **Fréchet-Ableitung:** Ist F Gâteaux-differenzierbar und gilt

$$F(u + h) = F(u) + F'(u)h + \tau(h) \quad \text{in } V$$

mit einer Funktion $\tau: U \rightarrow V$, die

$$\frac{\|\tau(h)\|_V}{\|h\|_U} \rightarrow 0 \quad \text{für} \quad \|h\|_U \rightarrow 0,$$

erfüllt, so heißt A *Fréchet-Ableitung*. Wir schreiben auch $\tau(h) \in o(\|h\|_U)$.

Beispiele 2.1.1. Einige Beispiele Fréchet-differenzierbarer Funktionen:

- (1) Sei $A \in \mathcal{L}(U, V)$ ein linearer stetiger Operator, $b \in V$ und $f(u) = Au + b$. Dann ist $f'(u)h = Ah$, also $f'(u) = A$.
- (2) Sei H ein Hilbertraum und $f: H \rightarrow \mathbb{R}$ gegeben durch $f(u) = \|u\|_H^2 = (u, u)_H$. Dann ist $f'(u)h = 2(u, h)_H$.
- (3) Sei $U = C[0, 1]$ und $V = \mathbb{R}$ und $f(u) = \sin(u(1))$. Dann ist $f'(u)h = \cos(u(1))h(1)$. Für ein solches Resultat braucht man eine Kettenregel.

chain rule

May 8, 2024

← Lecture 4

Lemma 2.1.2 (Kettenregel). *Es seien $F: U \rightarrow V$ und $G: V \rightarrow Z$ Fréchet-differenzierbar. Setze $E := G \circ F$. Dann gilt*

$$E'(u)h = G'(F(u)) \left[F'(u)h \right].$$

Beispiel 2.1.3. Es sei $A \in \mathcal{L}(U, H)$ und $b \in H$ mit $E(u) = \frac{1}{2}\|Au + b\|_H^2$, also $E = G \circ F: U \rightarrow \mathbb{R}$ mit $G: H \rightarrow \mathbb{R}$ gegeben durch $G(v) = \frac{1}{2}\|v\|_H^2$ und $F: U \rightarrow H$ gegeben durch $F(u) = Au + b$. Dann ist $G'(v) = (v, h)_H$ und $F'(u)h = Ah$, also nach der Kettenregel und mit den Riesz-Isomorphismen \mathcal{R}_H und \mathcal{R}_U von H und U :

$$\begin{aligned} E'(u)h &= (Au + b, Ah)_H = \langle \mathcal{R}_H^{-1}(Au + b), Ah \rangle_{H^*, H} \\ &= \langle A^* \mathcal{R}_H^{-1}(Au + b), h \rangle_{U^*, U} = (\mathcal{R}_U A^* \mathcal{R}_H^{-1}(Au + b), h)_U. \end{aligned}$$

Im Falle $U = H$ erhalten wir also

$$E'(u)h = (A^*(Au + b), h)_U.$$

Wir können nun für unsere einfache Modellaufgabe die notwendige Optimalitätsbedingung herleiten. Sei dazu \bar{u} ein lokales Minimum und $u \in U_{\text{ad}}$. Dann gilt $\bar{u} + t(u - \bar{u}) \in U_{\text{ad}}$ für $t \in [0, 1]$, da U_{ad} konvex angenommen war. Da zudem \bar{u} lokales Minimum ist, gilt für hinreichend kleines t

$$j(\bar{u}) \leq j(\bar{u} + t(u - \bar{u})),$$

also

$$0 \leq \frac{j(\bar{u} + t(u - \bar{u})) - j(\bar{u})}{t}, \quad \text{und mit } t \downarrow 0: \quad j'(\bar{u})(u - \bar{u}) \geq 0.$$

Das heißt, die notwendige Bedingung erster Ordnung sieht genauso aus wie im \mathbb{R}^n , also wie in der nichtlinearen Optimierung, für eine konvexe Nebenbedingung.

Für das konkrete j ergibt sich mit [Beispiel 2.1.3](#), wobei wir der Einfachheit halber $U = H$ annehmen,

$$j'(\bar{u})(u - \bar{u}) = (S^*(S\bar{u} - y_d) + \lambda\bar{u}, u - \bar{u})_U.$$

Damit lautet die notwendige Optimalitätsbedingung erster Ordnung

$$(S^*(S\bar{u} - y_d) + \lambda\bar{u}, u - \bar{u}) \geq 0 \quad \forall u \in U_{\text{ad}}. \quad (2.1.1)$$

Da wir ein konvexes Funktional auf einer konvexen Menge minimieren, ist diese Bedingung auch *hinreichend*.

2.2 Optimale Steuerung elliptischer Probleme

Wir wollen uns nun mit dem Minimierungsproblem aus dem ersten Kapitel beschäftigen, also mit

$$\min_{y, u \in L^2(\Omega)} J(y, u) := \frac{1}{2} \|y - y_d\|_{L^2(\Omega)}^2 + \frac{\lambda}{2} \|u\|_{L^2(\Omega)}^2$$

mit

$$\left. \begin{array}{l} -\Delta y = u \quad \text{in } \Omega \\ y = 0 \quad \text{auf } \Gamma \end{array} \right\} \quad (2.2.1)$$

und

$$u \in U_{\text{ad}} = \left\{ u \in L^2(\Omega) : u_a \leq u(x) \leq u_b \text{ fast überall auf } \Omega \right\}.$$

Wir setzen $\lambda \geq 0$ voraus. in advance Wir wollen dieses Problem auf die Struktur von Kapitel [2.1](#) bringen. Dazu setzen wir $H = U = L^2(\Omega)$. Der Operator S wird definiert über die schwache Lösung von [\(2.2.1\)](#), also $Su = y$, wenn

$$\int_{\Omega} \nabla y \cdot \nabla v \, dx = \int_{\Omega} u \cdot v \, dx \quad \forall v \in H_0^1(\Omega).$$

Das ist sinnvoll, denn [Satz 1.2.15](#) (Lax-Milgram) liefert uns die Stetigkeit der Abbildung $S: H_0^1(\Omega)^* \rightarrow H_0^1(\Omega)$. Diese ist tatsächlich auch stetig invertierbar. Da $H_0^1(\Omega) \hookrightarrow L^2(\Omega)$, also, $H_0^1(\Omega) \subseteq L^2(\Omega)$ und die Identitätsabbildung ist stetig, faktorisieren wir

$$L^2(\Omega) \cong L^2(\Omega)^* \hookrightarrow H_0^1(\Omega)^* \xrightarrow{S} H_0^1(\Omega) \hookrightarrow L^2(\Omega)$$

und erhalten S auch als stetigen linearen Operator

$$S: L^2(\Omega) \rightarrow L^2(\Omega), \quad u \mapsto y \text{ schwache Lösung von (2.2.1).}$$

Somit können wir im Zielfunktional y sinnvoll durch Su ersetzen. Die Existenz einer Lösung \bar{u} des Optimierungsproblems folgt somit unmittelbar aus [Satz 1.2.9](#). Die Lösung

immediately
close in space
sofort: close in zeit

ist sogar eindeutig, da unser Zielfunktional strikt konvex ist. Das sieht man im Fall $\lambda > 0$ sehr schnell. Im Fall $\lambda = 0$ benutzt man die Injektivität des Operators S .

Wir wollen nun die notwendige und hinreichende Optimalitätsbedingung aufstellen. Dafür benötigen wir den adjungierten Operator S^* . Laut Definition muss für alle $u, v \in L^2(\Omega)$ gelten, dass

$$(Su, v)_{L^2(\Omega)} = (u, S^*v)_{L^2(\Omega)}.$$

Sei $v \in L^2(\Omega)$ und sei $z \in H_0^1(\Omega)$ die eindeutige schwache Lösung des Problems

$$\begin{aligned} -\Delta z &= v & \text{in } \Omega \\ z &= 0 & \text{auf } \Gamma, \end{aligned}$$

sprich, es gilt

$$\int_{\Omega} \nabla z \cdot \nabla w \, dx = \int_{\Omega} w \cdot v \, dx \quad \forall w \in H_0^1(\Omega).$$

Sei $u \in L^2(\Omega)$ beliebig und schreiben wir $y = Su \in H_0^1(\Omega)$, so folgt mit dem vorigen

$$(Su, v)_{L^2(\Omega)} = \int_{\Omega} y \cdot v \, dx = \int_{\Omega} \nabla z \cdot \nabla y \, dx = \int_{\Omega} z \cdot u = (u, z)_{L^2(\Omega)}.$$

Es folgt, dass $S^*v = z$. Also ist S^* wieder der Lösungsoperator von (2.2.1) und wir erhalten $S = S^*$. Insbesondere ist S selbstadjungiert.

selfadjoint

In den Optimalitätsbedingungen steht der Ausdruck $S^*(S\bar{u} - y_d)$. Wir bezeichnen

$$\bar{p} = S^*(S\bar{u} - y_d)$$

als *adjungierten Zustand*. Wegen $\bar{y} = S\bar{u}$ und der Gestalt von S^* ist \bar{p} also durch

adjoint state

$$\int_{\Omega} \nabla v \cdot \nabla \bar{p} \, dx = \int_{\Omega} (\bar{y} - y_d) \cdot v \, dx \quad \forall v \in H_0^1(\Omega)$$

charakterisiert, oder in klassischer Schreibweise

$$\begin{aligned} -\Delta \bar{p} &= \bar{y} - y_d & \text{in } \Omega \\ \bar{p} &= 0 & \text{auf } \Gamma. \end{aligned}$$

Der Ausdruck $\bar{y} - y_d$ beschreibt hierbei den “Defekt” des Zielfunctionals.

Die Optimalitätsbedingung lautet folglich

$$(\bar{p} + \lambda \bar{u}, u - \bar{u})_{L^2(\Omega)} \geq 0 \quad \forall u \in U_{\text{ad}}.$$

Das gesamte Optimalitätssystem hat demnach die Form:

$$\begin{aligned} -\Delta \bar{y} &= \bar{u} & \text{in } \Omega, & & -\Delta \bar{p} &= \bar{y} - y_d & \text{in } \Omega, \\ \bar{y} &= 0 & \text{auf } \Gamma, & & \bar{p} &= 0 & \text{auf } \Gamma, \end{aligned}$$

$$(\bar{p} + \lambda \bar{u}, u - \bar{u})_{L^2(\Omega)} \geq 0 \quad \forall u \in U_{\text{ad}}.$$

Für viele Untersuchungen ist es sinnvoll, die Variationsungleichung

$$(\bar{p} + \lambda \bar{u}, u - \bar{u})_{L^2(\Omega)} \geq 0 \quad \forall u \in U_{\text{ad}} \tag{2.2.2}$$

äquivalent umzuformulieren. Ausgeschrieben lautet diese Beziehung

$$\int_{\Omega} (\bar{p}(x) + \lambda \bar{u}(x)) (u(x) - \bar{u}(x)) \, dx \geq 0 \quad \forall u \in U_{\text{ad}}.$$

Unser U_{ad} ist gegeben durch

$$U_{\text{ad}} = \left\{ u \in L^2(\Omega) : u_a \leq u(x) \leq u_b \text{ fast überall in } \Omega \right\}.$$

Daher muss die Ungleichung tatsächlich äquivalent punktweise fast überall gelten, also für fast jedes $x \in \Omega$:

$$(\bar{p}(x) + \lambda \bar{u}(x)) (u(x) - \bar{u}(x)) \geq 0 \quad \forall u \in U_{\text{ad}}. \tag{2.2.3}$$

Das sieht man so: Angenommen, es gäbe ein $u \in U_{\text{ad}}$, so dass die umgekehrte Ungleichung auf einer Menge A mit Maß $|A| > 0$ gälte. Dann wäre aber die Funktion

$$\hat{u}(x) := \chi_A(x)u(x) + \chi_{\Omega \setminus A}\bar{u}(x) = \begin{cases} u(x) & \text{in } A, \\ \bar{u}(x) & \text{sonst} \end{cases}$$

wieder in U_{ad} und es folgte

$$\int_{\Omega} (\bar{p}(x) + \lambda \bar{u}(x)) (\hat{u}(x) - \bar{u}(x)) \, dx = \int_A (\bar{p}(x) + \lambda \bar{u}(x)) (u(x) - \bar{u}(x)) \, dx < 0.$$

Das kann nicht sein, also gilt (2.2.3) eben doch punktweise für fast jedes $x \in \Omega$. Damit kann man nun noch etwas mehr arbeiten: Es folgt direkt

$$\bar{u}(x) = u_a \quad \text{für fast alle } x \in [\bar{p} + \lambda \bar{u} > 0]$$

und umgekehrt **reverse**

$$\bar{p}(x) + \lambda \bar{u}(x) \geq 0 \quad \text{für fast alle } x \in [\bar{u} = u_a], \tag{2.2.4}$$

und analog für u_b . Es bleibt die Menge $[\bar{p} + \lambda \bar{u} = 0]$. Für x aus dieser Menge unterscheiden

wir:

- $\lambda > 0$: Dann gilt

$$\bar{u}(x) = \frac{-\bar{p}(x)}{\lambda}.$$

Definiert man die konvexe Projektion

$$P_{[\alpha, \beta]}(z) = \begin{cases} z, & z \in [\alpha, \beta], \\ \alpha, & z < \alpha, \\ \beta, & z > \beta, \end{cases}$$

dann kann man die Variationsungleichung (2.2.2) bzw. (2.2.3) wiederum äquivalent schreiben als

$$\bar{u}(x) = P_{[u_a, u_b]} \left(-\frac{\bar{p}(x)}{\lambda} \right) \quad \text{für fast alle } x \in \Omega. \quad (2.2.5)$$

Im Fall $\lambda > 0$ vererbt sich die Regularität $\bar{p} \in H^1(\Omega)$ auf die optimale Steuerung \bar{u} , es treten aber in der Regel Knickstellen auf.

- $\lambda = 0$: Hier erhalten wir im Fall $x \in [\bar{p} = 0]$ *keine* Information für $\bar{u}(x)$ aus dem Optimalitätssystem. Die Lösungen können nun sehr unterschiedliche Gestalt besitzen. Wir betrachten zwei Extremfälle.

Extremfall 1: $\bar{y} \equiv y_d$

Damit können wir die gewünschte Funktion y_d exakt ansteuern und der optimale Zielfunktionswert ist Null. Wir erhalten

$$\begin{aligned} -\Delta \bar{p} &= \bar{y} - y_d = 0 & \text{in } \Omega \\ \bar{p} &= 0 & \text{auf } \Gamma \end{aligned}$$

und damit $\bar{p} \equiv 0$ auf ganz Ω . Die Optimalitätsbedingung enthält hier keine Information. Aus $\bar{y} \equiv y_d$ erhalten wir aber

$$\bar{u} = -\Delta \bar{y} = -\Delta y_d.$$

Extremfall 2: $|\{\bar{p} = 0\}| = 0$.

In diesem Extremfall nimmt die optimale Steuerung \bar{u} fast überall in Ω die extremalen Werte u_a bzw. u_b an, d.h.

$$\bar{u}(x) \in \{u_a, u_b\} \quad \text{fast überall in } \Omega.$$

Eine solche Struktur bezeichnet man als *Bang-Bang* und die Steuerung \bar{u} entsprechend als *Bang-Bang-Steuerung*, siehe Abbildung 2.1.

Wir müssen im Fall $\lambda = 0$ also sogar mit (einer Vielzahl von) Sprungstellen rechnen und die Regularität von \bar{u} geht nicht über das generische $L^2(\Omega)$ hinaus. Das hat potenziell Auswirkungen auf die numerische Analysis.




Abbildung 2.1: Bang-Bang Steuerung

Bemerkung 2.2.1. Bang-Bang-Steuerungen sind extremale Punkte der zulässigen Menge U_{ad} . Solche extremalen Punkte besitzen besondere Eigenschaften, die man ausnutzen kann.